

Universidad de los Andes

Departamento de Ingeniería Sistemas y Computación

ISIS 3302 – Modelado, Simulación y Optimización.

Proyecto 1: Optimización en logística para la empresa LogistiCo

Entrega 3-Implementación de Metaheurísticas:

1. Descripción del problema:

a. Formulación matemática base:

Conjuntos fundamentales:

- D : Deposito = $\{d_0\}$
- C : Clientes = $\{1, \dots, n\}$
- V : Vehículos = $\{1, \dots, m\}$

Parámetros Esenciales:

Para cada nodo $d \in D$ y $c \in C$:

- Lat: latitud del nodo
Unidades: grados
- Lon: Longitud del nodo
Unidades: grados

Para cada cliente $c \in C$:

- q_c : Demanda del cliente c
unidades: kg

Para cada vehículo $v \in V$:

- q_v : Capacidad de carga del vehículo
unidad: kg
- A_v : Autonomía del vehículo
Unidad: km
- R_v : Rendimiento del vehículo
Unidad: km/L
- C_v : Costo operativo por vehículo
Unidad: COP/día
- M_v : Costos de mantenimiento
Unidad: COP/km

Parámetros auxiliares:

- P_f : Precio del combustible
Unidad: COP/L
- C_t : Costo de transporte
Unidades: COP/km
- D_{ij} : Distancia entre los nodos i y j
Unidades: km
Se calcula usando las longitudes y latitudes.

Variables de decisión principales:

1. $X_{i,j,v} \in \{0,1\}$: $X_{d,c,v} = 1$ si el vehículo v viaja desde el nodo i al nodo j , de lo contrario será igual a 0.
2. $Y_v \in \{0,1\}$: $Y_v = 1$ si el vehículo v es utilizado, es decir, si sale del depósito.
3. $Z_{c,v} \in \{0,1\}$: $Z_{i,v} = 1$ si el cliente c es atendido por el vehículo v .
4. $L_{v,c} \geq 0$: variable continua que indica la carga del vehículo v al salir del nodo c .

Restricciones básicas:

Cada cliente debe ser atendido exactamente 1 vez:

$$\sum_{v \in V} Z_{c,v} = 1 \quad \forall c \in C$$

Un vehículo visita un cliente si entra y sale de él:

$$\begin{aligned} \sum_{c \in C} X_{j,i,v} &= Z_{c,v} \\ \sum_{c \in C} X_{i,j,v} &= Z_{c,v} \\ \forall c \in C, v \in V \end{aligned}$$

Capacidad por vehículo:

$$\sum_{c \in C} q_c Z_{c,v} \leq q_v Y_v \quad \forall v \in V$$

Ruta del vehículo no supera autonomía:

$$\sum_{i \in C} \sum_{j \in C} D_{i,j} X_{i,j,v} \leq A_v Y_v \quad \forall v \in V$$

Función objetivo base:

Minimizar la suma de todos los costos operativos:

$$\min \sum_{v \in V} C_v Y_v + \sum_{v \in V} \sum_{i \in C} \sum_{j \in C} X_{i,j,v} (C_t D_{i,j} + P_f \frac{D_{i,j}}{R_v} + M_v D_{i,j})$$

b. Características de la instancia base:

La instancia base contiene 3 tablas diferentes (clientes, vehículos y depósito), donde de cada una de ellas se extrae lo estrictamente necesario para tener los datos completos.

Así mismo se genera una matriz de distancias que contiene las distancias entre el depósito y los clientes y entre clientes y se modela un formato de penalizaciones en donde por cliente no asignado y por exceder la capacidad del vehículo se le asigna un valor alto para forzar la factibilidad.

c. Restricciones y consideraciones:

- Cada ruta por vehículo no debe exceder la capacidad, si lo hace, se le aplica una penalización.
- Cada cliente debe ser atendido exactamente una vez, cliente no atendido se penaliza fuertemente.
- Se tienen en cuenta los costos operativos por vehículo y los costes temporales.

2. Método implementado:

a. Descripción detallada:

Se implementó un algoritmo genético (GA) con representación por permutación para abordar el problema, inicialmente se genera permutaciones aleatorias de los n clientes en donde cada permutación se convierte en un conjunto de rutas (una ruta por vehículo), esto lo hace la función “decode_permutation_to_routes” la cual se encarga de hacer esta decodificación y teniendo en cuenta que si un cliente no cabe en ningún vehículo este se marca como “leftover”.

Luego se hace un proceso de reparación con la ayuda de la función “repair_insert” la cual inserta estos clientes no asignados en las rutas existentes probando todas las posibles opciones y escogiendo la opción que minimice el incremento de los costos basados en la distancia, esto se hace hasta que no se puedan ingresar más clientes.

Con la ayuda de la función “fitness_from_routes” calcula el costo total de la ruta y asigna penalizaciones ya sea por capacidad superada o clientes no asignados.

Luego se hace el proceso de selección implementado como un torneo para seleccionar los padres y se genera un cruce conservando subsecuencias de un padre y rellenando con el orden del otro.

Finalmente se usan dos mecanismos para realizar las mutaciones, intercambiando dos genes con la ayuda de “mutate_swap” y una inversión del subsegmento con ayuda de “mutate_inversion”, luego se hace una elección por elitismo seleccionando los mejores individuos entre generaciones y se repite por la cantidad de generaciones que se haya definido manteniendo la historia del mejor coste por generación.

b. Estrategias de representación y operadores:

Se escogió la representación del cromosoma como un solo vector de permutaciones de 1 hasta n ya que es simple, compacta y ampliamente usada para TSP.

Además, como se mencionó anteriormente se decodifica heurísticamente iterando los clientes en el orden dado por la permutación manteniendo el índice del vehículo que va rotando cada vez que este no entra a una ruta actual.

Se usan los operadores genéticos cruce manteniendo una subsecuencia del primer progenitor y rellenando con el orden del segundo, mutaciones intercambiando de dos posiciones y realizando un cambio en las inversiones de un segmento afectado el orden iterativo en un bloque y finalmente selección con un torneo k ($k=3$ = seleccionando individuos con menor coste).

c. Proceso de Calibración de parámetros:

El código presenta los siguientes valores como punto de partida sin embargo se puede realizar ciertas modificaciones dependiendo del objetivo:

pop_size = 40

generations = 80

crossover_prob = 0.9.

mutation_prob = 0.2 (swap) y $\text{mutation_prob} * 0.5$ para inversión.

elitism = 2.

random_seed = 1 para reproducibilidad.

penalty_unassigned = $1e7$ (penaliza fuertemente clientes no atendidos).

3. Resultados Experimentales:

a. Caso base:

En la figura 1 podemos observar la curva de convergencia del algoritmo genérico, en donde el eje horizontal se encuentran las generaciones y en el vertical el mejor coste encontrado por generación. Analizando su comportamiento podemos ver que el coste fue disminuyendo como era la intención en la función objetivo, sin embargo, este descenso fue por saltos, en donde disminuía una cantidad ((la cual con el paso e generaciones disminuía menos) y luego se mantenía constante durante un numero de generaciones que iba aumentando, por lo que podemos ver que al final convergió de una buena manera en la generación 62 aproximadamente.




Figura 1. Grafica de Convergencia del GA

En la figura 2 podemos observar dos graficas, la de la izquierda un histograma donde podemos evidenciar que la carga fue distribuida en 3 vehículos (115,125,137) cada valor de carga fue transportado por un vehículo distinto, y la grafica de la derecha un boxplot en donde hay dos cajas la primera muestra que la carga tiene una mediana aproximadamente de 125 un mínimo de 113 y un

máximo de 127, en donde en conjunto las cargas están relativamente agrupadas y la segunda es la distancia la cual esta en una escala más pequeña y tiene una mediana alrededor de 46.




Figura 2. Histograma y Boxplot de base

En la figura 3 podemos observar como se distribuyeron los caminos y como quedaron las rutas finales, podemos ver que se usaron los vehículos V001, V002 y V003, los cuales todos iniciaban desde el depósito y volvían a él, el V001 llevó una carga de 126 y realizó la siguiente ruta C018 - C002 - C019 - C007 - C021 - C012 - C023 - C014 - C020, el vehículo V002 llevó 138 y esta fue su ruta C003 - C013 - C015 - C010 - C016 - C001 - C004 - C022 - C006

Igualando la cantidad de cliente con el vehículo 1 pero superándolo en carga y finalmente el vehículo 3 fue el que menor carga llevó con un total de 113 y fue el que menos clientes visitó con la siguiente ruta: C005 - C008 - C009 - C011 - C024 - C017. Por otro lado, podemos ver que ningún vehículo superó su capacidad y todos los clientes fueron visitados por un vehículo.




Figura 3. Rutas asignadas por el GA caso base

Recordando los resultados de pyomo anteriores en la figura 4 podemos ver la ruta asignada, para esta ruta el mínimo coste dio aproximadamente 800,00 COP y utilizando nuestro algoritmo genético dio 232,767, podemos evidenciar que hubo una mejor evidente, así mismo con respecto a las rutas podemos ver que la asignación de rutas con pyomo no está segmentada, es decir, pyomo simplemente minimizo los costos pero no optimizó las rutas, en el caso del algoritmo genético podemos ver que las rutas están segmentadas por vehículo y zona, es decir los vehículos intenta cubrir una distribución de clientes específica y no cubren clientes que están muy lejos de ella por eso podemos evidenciar el bajo costo que esta solución logra dar.




Figura 4. Rutas asignadas por Pyomo caso base

b. Caso 2:

La gráfica de convergencia del Algoritmo Genético para el Caso 2 muestra un comportamiento de la metaheurística, con una rápida mejora en las primeras generaciones y una posterior estabilización de la solución. Inicialmente, el costo presenta un valor elevado cercano a los 339.000 COP, lo que corresponde a soluciones de baja calidad en las primeras poblaciones. En las siguientes generaciones se observa una reducción abrupta del costo hasta aproximadamente 331.000 COP, seguida de una nueva mejora significativa que alcanza un valor cercano a 278.000 COP alrededor de la generación 8. A partir de este punto, el algoritmo entra en una fase clara de convergencia, manteniendo el mejor costo prácticamente constante hasta la generación 120, lo que indica que el GA encontró una solución estable y no logró mejoras adicionales. Comparativamente, frente al resultado del modelo exacto en Pyomo para el Caso 2 (238.218 COP), la solución del GA presenta un costo superior, lo cual es consistente con la naturaleza aproximada de las metaheurísticas; sin embargo, el GA logra esta solución en un tiempo computacional significativamente menor, evidenciando el trade-off entre calidad de solución y eficiencia computacional, especialmente relevante para escenarios de mayor complejidad donde Pyomo pierde escalabilidad.








Figura 5 Convergencia

Las gráficas de cumplimiento de ventanas de tiempo muestran que tanto la metaheurística basada en Algoritmo Genético como la implementación exacta en Pyomo logran respetar las ventanas de tiempo de todos los clientes, ya que en ambos casos los puntos de llegada se encuentran dentro de las barras grises que representan los intervalos permitidos. En la solución obtenida por el GA se observa una distribución temporal más flexible, con ciertos clientes atendidos ligeramente al inicio de sus ventanas, lo cual evidencia la capacidad adaptativa del algoritmo para reorganizar secuencias sin violar restricciones. Por su parte, la solución de Pyomo presenta una estructura temporal más compacta y ordenada, especialmente en los clientes atendidos por la camioneta, reflejando la naturaleza exacta del modelo, que optimiza simultáneamente rutas, tiempos y costos bajo todas las restricciones activas.

Al contrastar estos resultados con los valores documentados del Caso 2 en Pyomo, se confirma que la asignación híbrida es coherente: el dron atiende los clientes más cercanos y con ventanas tempranas, mientras que la camioneta consolida los clientes más alejados en una sola ruta, cumpliendo capacidades, autonomía y tiempos de servicio. Esto se alinea con los resultados reportados, donde Pyomo logró un costo total de 238.218 COP, con cargas de 167/200 kg para la camioneta y 18/25 kg para el dron, además de distancias de 26.054 km y 10.317 km respectivamente. En comparación, aunque el GA obtiene una solución de mayor costo, su planificación sigue siendo temporalmente factible y operativamente coherente, manteniendo el patrón híbrido de atención y demostrando que la metaheurística preserva las restricciones críticas del problema, a cambio de sacrificar parte de la optimalidad económica. En conjunto, estos resultados confirman el trade-off clásico entre optimalidad y eficiencia computacional, donde Pyomo ofrece la mejor calidad de solución y el GA una alternativa viable, escalable y rápida para escenarios de mayor complejidad.




Al comparar las rutas obtenidas para el Caso 2 mediante la implementación exacta en Pyomo y la solución generada por el Algoritmo Genético, se observa que en ambos enfoques se mantiene la lógica híbrida del problema, donde la camioneta atiende los clientes más dispersos y el dron se encarga de los puntos más cercanos al depósito. En la solución de Pyomo, las rutas presentan una estructura más compacta y ordenada, con trayectorias claramente diferenciadas entre ambos vehículos, minimizando cruces innecesarios y consolidando de forma eficiente los recorridos de la camioneta en una sola secuencia principal. Por su parte, la solución del GA conserva el mismo patrón general de asignación, pero muestra trayectorias más irregulares, con mayores cruces entre rutas y saltos más largos para el dron, lo que explica el aumento en el costo total frente a Pyomo. Aun así, la solución metaheurística sigue siendo completamente factible, respeta la separación funcional entre dron y camioneta, y reproduce de forma coherente la estrategia híbrida del modelo exacto, confirmando que el GA logra capturar correctamente la estructura del problema, aunque con menor eficiencia espacial.




c. Caso 3:


La evolución del costo obtenida mediante el Algoritmo Genético para el caso 3 presenta un descenso pronunciado durante las primeras generaciones. El costo comienza en un valor cercano a los 289.000 COP, correspondiente a soluciones aleatorias. En las primeras generaciones el algoritmo logra reducciones significativas, alcanzando valores aproximados de 250.000 COP hacia la generación 10. Después el costo continúa disminuyendo de manera progresiva hasta converger hacia el monto de 222.000 COP a partir de la generación 30.



En cuanto a las ventanas de tiempo, el algoritmo genético respeta las restricciones temporales de todos los clientes. Se observa en el gráfico que cada punto de inicio de servicio se encuentra contenido dentro del intervalo permitido por su respectiva ventana de tiempo. El GA no solo optimiza el costo, sino que también garantiza la factibilidad temporal de la solución.



Finalmente, el análisis de las rutas obtenidas. Permite observar que la camioneta realiza un recorrido continuo que parte desde el depósito, visita la totalidad de los clientes y retorna al punto inicial. La ruta presenta algunos cruces y trayectorias no completamente lineales, lo cual es característico de soluciones obtenidas mediante metaheurísticas. La solución encontrada es completamente factible desde el punto de vista operativo y espacial.



4. Análisis de sensibilidad:

El análisis de sensibilidad realizado sobre el Caso 2 evidencia la robustez del Algoritmo Genético (GA) frente a variaciones en parámetros críticos del sistema. En el escenario base, el GA reduce el costo desde un valor inicial cercano a 344.579 COP hasta aproximadamente 326.822 COP en la generación 15, mostrando una mejora progresiva y estable. Al incrementar los costos operativos en un 20 %, el algoritmo mantiene el mismo patrón de convergencia, partiendo de un costo inicial de 413.494 COP y alcanzando valores cercanos a 392.186 COP, lo que confirma una respuesta coherente ante aumentos directos en la función objetivo. De igual forma, al reducir el rango del dron en un 15 % y disminuir su velocidad en el mismo porcentaje, el GA conserva su capacidad de encontrar soluciones factibles, con costos finales del orden de 326.822 COP y 326.845 COP respectivamente, muy cercanos al escenario base. Estos resultados indican que la metaheurística no solo es capaz de adaptarse a cambios operativos relevantes, sino que también presenta estabilidad estructural, ya que las variaciones en los parámetros afectan el valor absoluto del costo, pero no deterioran de manera significativa la calidad relativa de la solución ni el proceso de convergencia.

```
st01 ciudad_cas02.py
INFO: Escenario baseline - Pyomo
INFO: Escenario baseline - GA
INFO: Inicial: mejor coste 344578.59
INFO: Gen 1: nuevo mejor 343910.50
INFO: Gen 2: nuevo mejor 330875.14
INFO: Gen 3: nuevo mejor 329857.97
INFO: Gen 8: nuevo mejor 327052.44
INFO: Gen 15: nuevo mejor 326821.71
INFO: Escenario costs_up_20 - Pyomo
INFO: Escenario costs_up_20 - GA
INFO: Inicial: mejor coste 413494.30
INFO: Gen 1: nuevo mejor 412692.60
INFO: Gen 2: nuevo mejor 397050.17
INFO: Gen 3: nuevo mejor 395829.56
INFO: Gen 8: nuevo mejor 392462.93
INFO: Gen 15: nuevo mejor 392186.05
INFO: Escenario range_drone_down_15 - Pyomo
INFO: Escenario range_drone_down_15 - GA
INFO: Inicial: mejor coste 344578.59
INFO: Gen 1: nuevo mejor 343910.50
INFO: Gen 2: nuevo mejor 330875.14
INFO: Gen 3: nuevo mejor 329857.97
INFO: Gen 8: nuevo mejor 327052.44
INFO: Gen 15: nuevo mejor 326821.71
INFO: Escenario speed_drone_down_15 - Pyomo
INFO: Escenario speed_drone_down_15 - GA
INFO: Inicial: mejor coste 344599.67
INFO: Gen 1: nuevo mejor 343930.00
INFO: Gen 2: nuevo mejor 330886.77
INFO: Gen 3: nuevo mejor 329879.05
INFO: Gen 8: nuevo mejor 327087.06
INFO: Gen 15: nuevo mejor 326845.03
INFO: Resumen guardado en verificaciones/analisis/
7.csv
```

5. Discusión y Conclusiones:

Los resultados obtenidos en los tres casos permiten evidenciar que el Algoritmo Genético (GA) es una herramienta efectiva para la solución de problemas de ruteo con restricciones de capacidad, ventanas de tiempo y múltiples vehículos. En el Caso Base, el GA logró una solución factible con una segmentación adecuada de clientes por zonas, aunque con un costo superior al obtenido por el modelo exacto en Pyomo, lo cual es consistente con la naturaleza aproximada de las metaheurísticas.

En el Caso 2, donde se incorporó la operación híbrida entre camioneta y dron, se confirmó que Pyomo produce la solución de menor costo, mientras que el GA replica correctamente la lógica del problema, asignando al dron los clientes cercanos al depósito y a la camioneta los más lejanos. Si bien el costo obtenido por el GA es mayor, este mantiene la factibilidad total del sistema y reduce significativamente el tiempo de cómputo frente al método exacto.

En el Caso 3, resuelto únicamente con el GA, se observó una convergencia rápida hacia una solución estable, con cumplimiento total de las ventanas de tiempo y una ruta operativamente coherente. Esto confirma la capacidad del GA para escalar a problemas de mayor complejidad sin afectar la viabilidad de la solución.

El análisis de sensibilidad realizado sobre el Caso 2 mostró que el GA conserva su estabilidad ante variaciones en parámetros críticos como costos,

rango y velocidad del dron, afectando únicamente el valor del costo final, pero no la factibilidad de las soluciones.

En conclusión, aunque Pyomo garantiza soluciones óptimas, el Algoritmo Genético se consolida como una alternativa eficiente, flexible y escalable para problemas logísticos complejos, ofreciendo un equilibrio adecuado entre calidad de solución y eficiencia computacional.